

# Регрессионный анализ социально-экономических процессов

Модели бинарного выбора

26 января 2026

## Вопрос

Покажем, что такое линейная вероятностная модель (linear probability model)

## Вопрос

Покажем, что такое линейная вероятностная модель (linear probability model)

## Ответ

Это результат оценивания классической линейной регрессии применительно к случаю бинарного отклика:

$y_i = \beta_0 + \beta x_i + e_i$ , где  $y_i$  принимает только два значения, где, к примеру, 1 – приняли рукопись к публикации, 0 – в противном случае.

## Вопрос

Покажем, что такое линейная вероятностная модель (linear probability model)

## Ответ

Это результат оценивания классической линейной регрессии применительно к случаю бинарного отклика:

$y_i = \beta_0 + \beta x_i + e_i$ , где  $y_i$  принимает только два значения, где, к примеру, 1 – приняли рукопись к публикации, 0 – в противном случае.

В этом случае предсказанное значение отклика ( $\hat{y}_i$ ) – это вероятность того, что  $Y$  принимает значение 1:

$$E(y_i|x_i) = 1 \times P(y_i = 1|x_i) + 0 \times P(y_i = 0|x_i) = P(y_i = 1|x_i)$$

## Вопрос

В чем основные ограничения линейной вероятностной модели?

## Вопрос

В чем основные ограничения линейной вероятностной модели?

## Ответ

- 1 Предсказанные значения отклика выходят за допустимые границы, может быть меньше 0 или больше 1

## Вопрос

В чем основные ограничения линейной вероятностной модели?

## Ответ

- 1 Предсказанные значения отклика выходят за допустимые границы, может быть меньше 0 или больше 1
- 2 Содержательно не всегда правдоподобной является линейная взаимосвязь вероятности «успеха» и объясняющей переменной

## Вопрос

Рассмотрим альтернативу. В чем суть подхода, основанного на латентной зависимой переменной?



## Вопрос

Рассмотрим альтернативу. В чем суть подхода, основанного на латентной зависимой переменной?

## Ответ

Мы допускаем, что существует некоторая ненаблюдаемая переменная  $y_i^*$ , принимающая любые значения  $(-\infty; +\infty)$

Условно ее можно интерпретировать как склонность к «успеху» (склонность к тому, что наблюдаемый  $y_i = 1$ )

На основе значений  $y_i^*$  определяются значения исходного  $y_i$ .

Если  $y_i^* > 0$ , то  $y_i = 1$

Если  $y_i^* \leq 0$ , то  $y_i = 0$

## Вопрос

Запишем спецификацию модели с  $y_i^*$  в качестве отклика.  
Какие допущения делаем об ошибках?

## Вопрос

Запишем спецификацию модели с  $y_i^*$  в качестве отклика.  
Какие допущения делаем об ошибках?

## Ответ

Важно, что латентная зависимая переменная линейным образом связана с объясняющими переменными:

$$y_i^* = \beta_0 + \beta x_i + e_i$$


Так как отклик ненаблюдаемый, нам нужны допущения о распределении ошибок:

- 1  $e \sim N(0, 1)$  (probit-model)
- 2 стандартное логистическое распределение  $e \approx N(0, 3.29)$

(logit-model). 
$$F(e) = \frac{\exp(e)}{1 + \exp(e)}$$


# Графики функций плотности

Panel A: pdf's for logistic and normal distributions



# Графики функций распределения

Panel B: cdf's for logistic and normal distributions



## Вопрос

Покажем, что  $P(y_i = 1) = F(\beta_0 + \beta x_i)$ , где  $F$  – функция распределения.

## Вопрос

Покажем, что  $P(y_i = 1) = F(\beta_0 + \beta x_i)$ , где  $F$  – функция распределения.

## Ответ

$$P(y_i = 1) =$$

## Вопрос

Покажем, что  $P(y_i = 1) = F(\beta_0 + \beta x_i)$ , где  $F$  – функция распределения.

## Ответ

$$P(y_i = 1) = P(y_i^* > 0) =$$



## Вопрос

Покажем, что  $P(y_i = 1) = F(\beta_0 + \beta x_i)$ , где  $F$  – функция распределения.

## Ответ

$$P(y_i = 1) = P(y_i^* > 0) = P(\beta_0 + \beta x_i + e_i > 0) =$$

## Вопрос

Покажем, что  $P(y_i = 1) = F(\beta_0 + \beta x_i)$ , где  $F$  – функция распределения.


## Ответ

$P(y_i = 1) = P(y_i^* > 0) = P(\beta_0 + \beta x_i + e_i > 0) = P(e_i \leq \beta_0 + \beta x_i)$ ,  
а функция распределения – это и есть вероятность того, что сл. величина не превышает указанное значение.


К примеру, для логит-модели:

$$P(y_i = 1) = F(\beta_0 + \beta x_i) = \frac{\exp(\beta_0 + \beta x_i)}{1 + \exp(\beta_0 + \beta x_i)}$$

# Зависимость $P(Y = 1)$ от $X$ ...



...в результате той самой ползущей «улитки»



Можно обойтись и без латентного  $y_i^*$ :

Можно обойтись и без латентного  $y_i^*$ :

## Ответ

- 1 Перейдем от  $P(y_i = 1)$  к шансам  $\frac{P(y_i = 1)}{1 - P(y_i = 1)}$

Можно обойтись и без латентного  $y_i^*$ :

## Ответ

- 1 Перейдем от  $P(y_i = 1)$  к шансам  $\frac{P(y_i = 1)}{1 - P(y_i = 1)}$
- 2 Запишем  $P(y_i = 1)$  как функцию распределения:

$$\frac{\frac{\exp(\beta_0 + \beta x_i)}{1 + \exp(\beta_0 + \beta x_i)}}{1 - \frac{\exp(\beta_0 + \beta x_i)}{1 + \exp(\beta_0 + \beta x_i)}} = \exp(\beta_0 + \beta x_i)$$

Можно обойтись и без латентного  $y_i^*$ :

## Ответ

1. Перейдем от  $P(y_i = 1)$  к шансам  $\frac{P(y_i = 1)}{1 - P(y_i = 1)}$
2. Запишем  $P(y_i = 1)$  как функцию распределения:
$$\frac{\exp(\beta_0 + \beta x_i)}{1 + \exp(\beta_0 + \beta x_i)} = \frac{P(y_i = 1)}{1 - P(y_i = 1)}$$
3.  $\ln\left(\frac{P(y_i = 1)}{1 - P(y_i = 1)}\right) = \beta_0 + \beta x_i$  (логит линейным образом связан с объясняющими переменными)



## Вопрос

Что из себя представляет confusion matrix? Как ее построить?

## Вопрос

Что из себя представляет confusion matrix? Как ее построить?

## Ответ

- 1 Сначала нужно сохранить предсказанные моделью вероятности  $P(Y = 1)$
- 2 Далее выбрать порог отсечения: к примеру, если  $P(Y = 1)$  более 0.5 отнести наблюдение к классу 1, и в противном случае – к классу 0.
- 3 Далее на основе предсказанных и наблюдаемых значений можно построить аналог таблицы сопряженности

## Вопрос

Рассмотрим элементы confusion matrix подробнее.

## Вопрос

Рассмотрим элементы confusion matrix подробнее.

## Ответ

$$\begin{pmatrix} \text{prediction : } Y = 1 & TP & FP \\ \text{prediction : } Y = 0 & FN & TN \end{pmatrix}, \text{ где}$$

TP – истинно «положительные» значения (в реальности относится к классу 1 и классифицировано моделью так же)

TN – по аналогии: истинно «отрицательные» значения

FP – допущена ошибка классификатором: отнесли к классу 1 («положительные»), а на самом деле – класс 0

FN – допущена ошибка классификатором: отнесли к классу 0 («отрицательные»), а на самом деле – класс 1

## Вопрос

Определите по этой confusion matrix ошибку I рода, ошибку II рода и мощность критерия.

## Вопрос

Определите по этой confusion matrix ошибку I рода, ошибку II рода и мощность критерия.

## Ответ

$$\begin{pmatrix} \text{prediction : } Y = 1 & \text{data : } Y = 1 & Y = 0 \\ \text{prediction : } Y = 0 & TP & FP \\ & FN & TN \end{pmatrix},$$

$$\text{ошибка I рода} = P(\text{reject} | H_0) = \frac{FP}{FP + TN}$$

$$\text{ошибка II рода} = P(\text{NOT reject} | H_1) = \frac{FN}{FN + TP}$$

$$\text{мощность} = P(\text{reject} | H_1) = \frac{TP}{FN + TP}$$

## Чтобы confusion matrix не смогла Вас confuse:

- 1 Когда считаете ошибку I рода, вспоминайте, что теперь массив сужается только до Н0 (класс 0 по ИСХОДНЫМ ДАННЫМ): отвержение при условии верной Н0. Мысленно оставляйте в матрице только тот столбец, который соответствует (data:  $Y = 1$ ), то есть,  $TN + FP$ . А дальше зададимся вопросом, когда допускается ошибка?  
 $FP$  – это, конечно, же ошибка, поэтому и получаем
$$\frac{FP}{FP + TN}$$
- 2 По аналогии делайте и при расчете ошибки II рода: только теперь Вас интересует подмассив «класс 1»

## Вопрос

Что такое меры чувствительности (sensitivity) и специфичности (specificity)?



## Вопрос

Что такое меры чувствительности (sensitivity) и специфичности (specificity)?

## Ответ

Когда считаем эти меры, нас всегда будет интересовать, какую долю наблюдений мы классифицировали моделью ВЕРНО (относительно исходных данных). Осталось только запомнить, что чувствительность – это про верные «положительные» наблюдения, а специфичность – про верные «отрицательные».

$$\text{Sensitivity} = \frac{TP}{TP + FN}; \text{Specificity} = \frac{TN}{TN + FP}$$

## Несложно заметить, что

Sensitivity – это мощность критерия (которую мы всегда хотим максимизировать).

Specificity – это  $(1 - \text{ошибка I рода})$ , эту величину тоже хочется максимизировать.

Однако одновременно это сделать на практике сложно, для того, чтобы найти подходящее пороговое значение (насколько это возможно, максимизирующее мощность и минимизирующее ошибку I рода) нам пригодится ROC. См. полезный интерактив с бегунком по ROC – [здесь](#).

## Меры качества модели: $R^2$

Для логистических моделей, так же как и для классических линейных, существуют  $R^2$ , только они псевдо- $R^2$ . Они основаны на функции правдоподобия модели и НЕ могут интерпретироваться как доля объясненной вариации. Подробнее про разные варианты pseudo- $R^2$  можно посмотреть [здесь](#).