Регрессионный анализ социально-экономических процессов

Автокорреляция. Модели с лагированными переменными

Временная автокорреляция

Нарушение допущения о независимости ошибок в разные временные периоды: $cov(\varepsilon_{it}, \varepsilon_{is}) \neq 0$, где $t \neq s$

Можем определить, насколько зависит значение ряда в текущий временной период от предшествующих. Если нас интересует, к примеру, лаг $L = 1$, тогда сравним ряд с самим собой, но предварительно сдвинув ряд на один временной период:

	t = 1	t = 2	t = 3	t = 4	t = 5
$\hat{\varepsilon}_t$	$\hat{\varepsilon}_1$	$\hat{\varepsilon}_2$	$\hat{\varepsilon}_3$	$\hat{\varepsilon}_4$	$\hat{\varepsilon}_5$
$\hat{\varepsilon}_{t-1}$	NA	$\hat{\varepsilon}_1$	$\hat{\varepsilon}_2$	$\hat{\varepsilon}_3$	$\hat{\varepsilon}_4$

$\rho = cor(\hat{\varepsilon}_t, \hat{\varepsilon}_{t-1})$ – коэффициент автокорреляции

Пример: авторегрессия первого порядка

AR(1): $y_t = \beta_0 + \rho y_{t-1} + w_t$, где $w_t \sim i.i.d.(0, \sigma^2)$

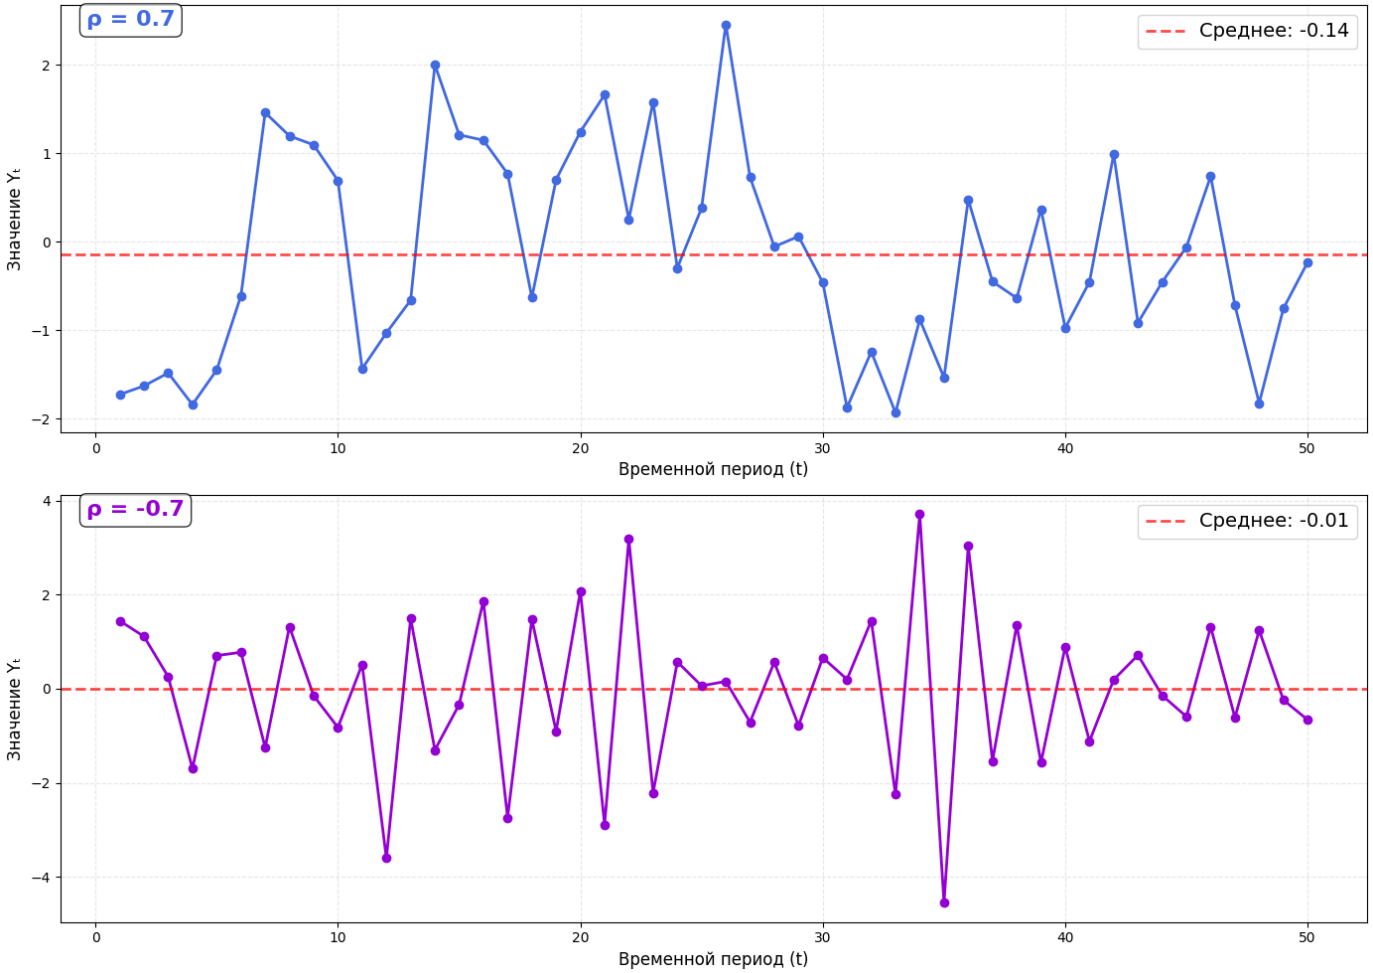

Последствия автокорреляции

В условиях автокорреляции МНК-оценки коэффициентов больше не являются BLUE: они становятся неэффективными, но при этом остаются несмещенными и состоятельными. То есть, мы делаем некорректные выводы относительно значимости коэффициентов

Стационарность

Стационарность предполагает, что характеристики временного ряда постоянны (т.е., не зависят от времени):

1. $E(y_t) = a$
2. $Var(y_t) = \sigma^2$
3. $Cov(y_t, y_{t-k}) = c$, для фиксированного значения k

AR(1): $y_t = \hat{\beta}_0 + \hat{\rho} y_{t-1} + w_t$
При стационарности $|\rho| < 1$

Если ряд нестационарный, тогда распределение y_t будет меняться со временем, что приводит к невозможности опираться на результаты оценивания модели и тестирования значимости

Пример нестационарности (1)

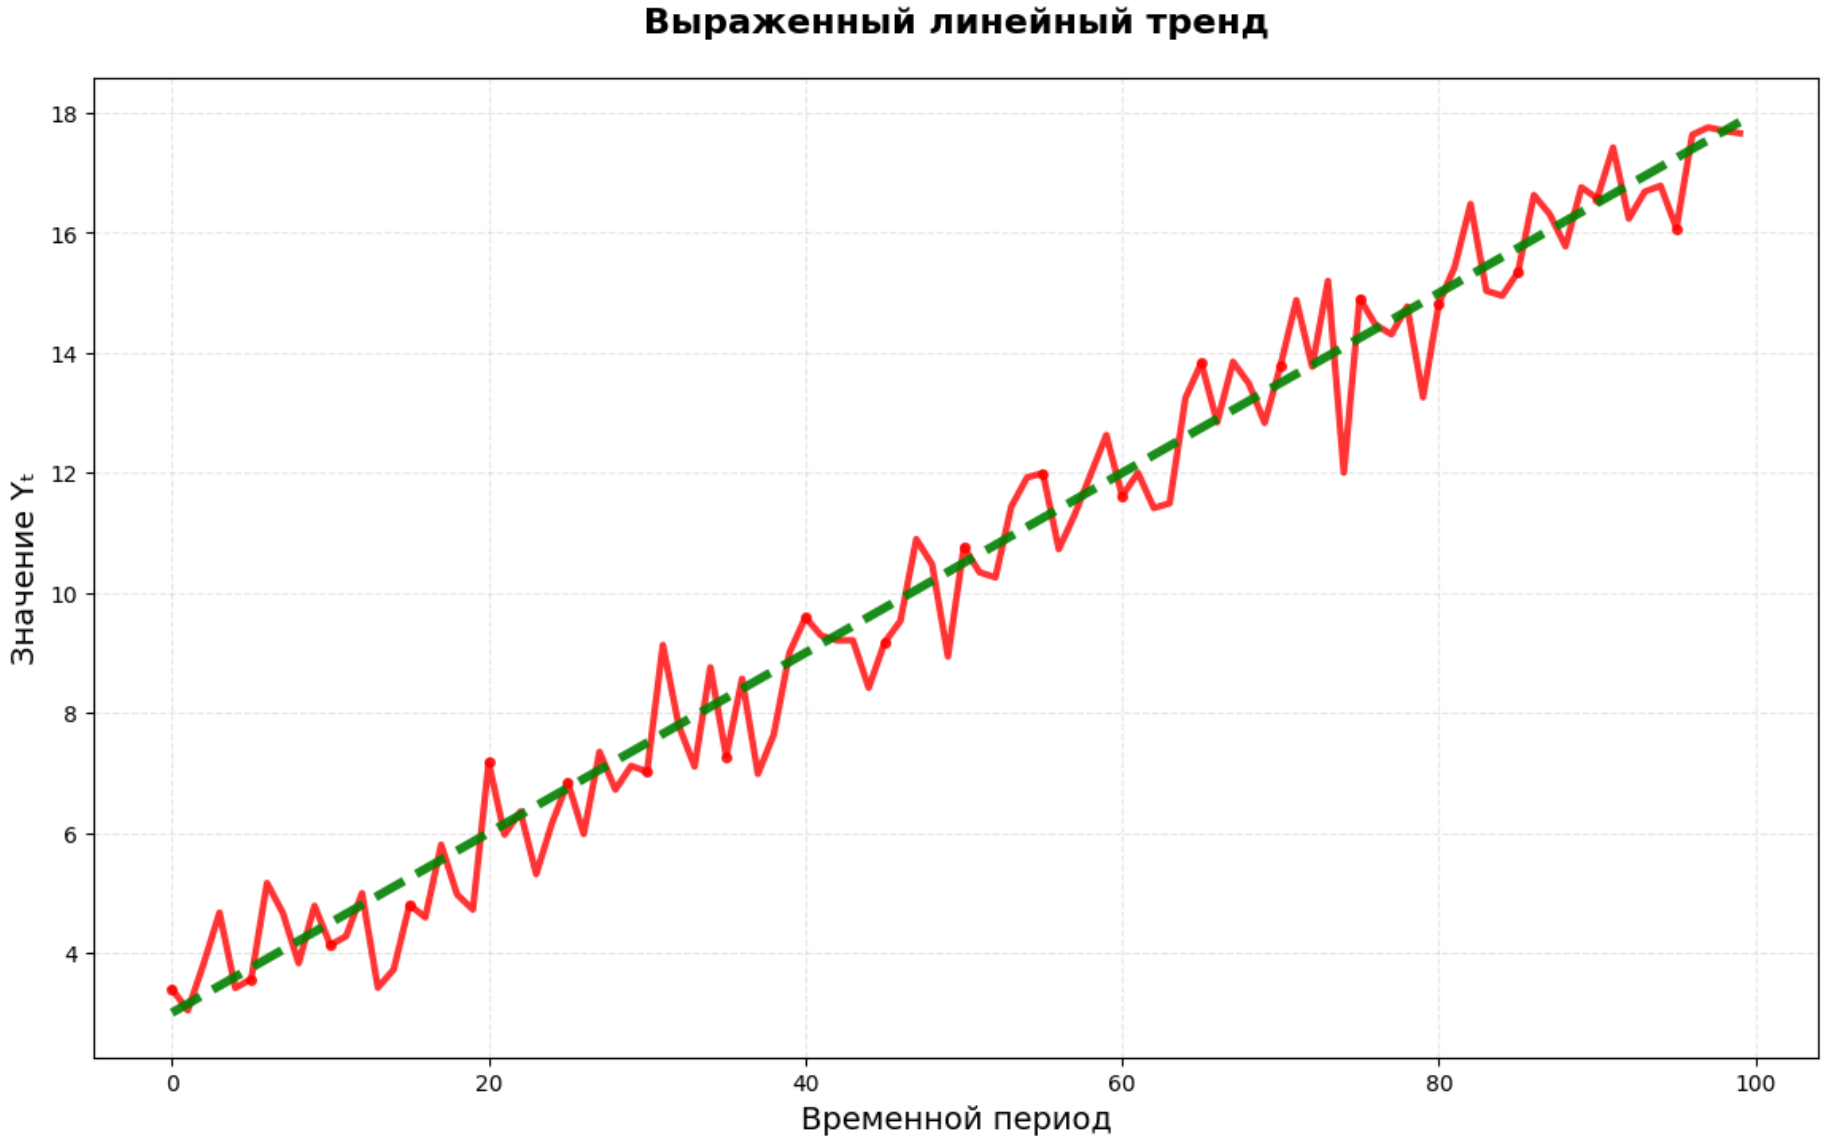

Пример нестационарности (2)

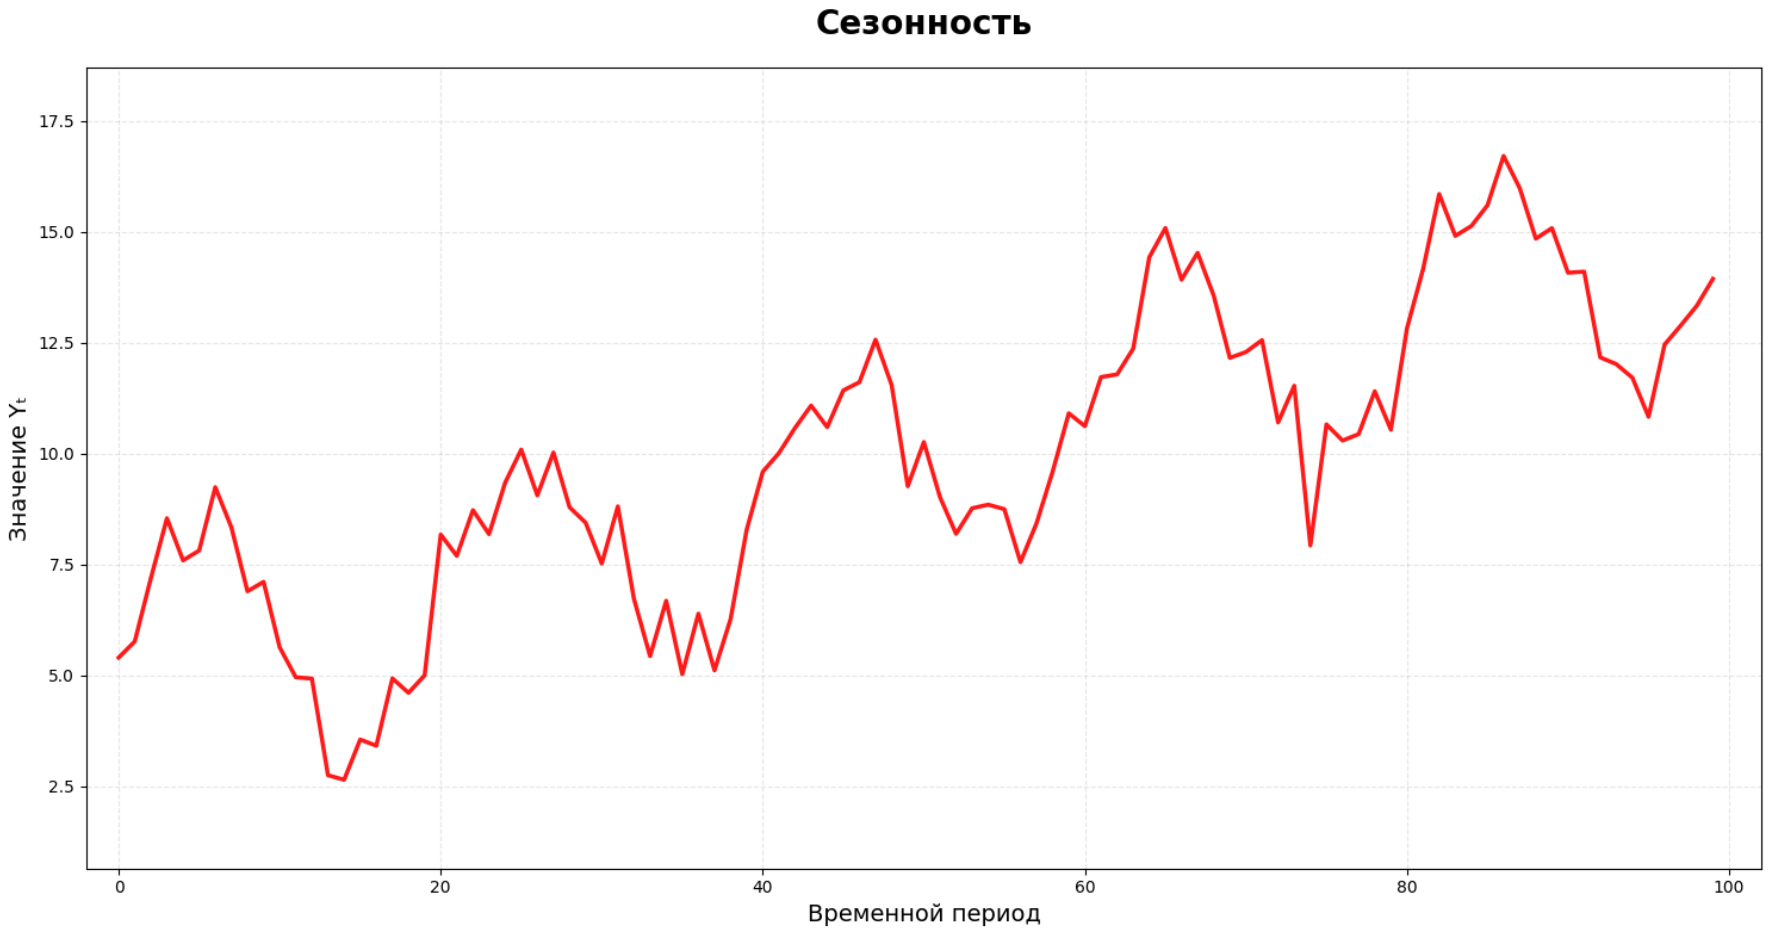

Диагностика автокорреляции

1. графические способы:
   - график остатков во времени
   - график автокорреляционной функции (ACF) и частной автокорреляционной функции (PACF)
2. формальные тесты
   - на практике будем использовать тест Бреуша–Годфри (Breusch-Godfrey)
   - в литературе встречается тест Дарбина–Уотсона (Durbin–Watson). В связи с рядом его ограничений (в частности, в связи с тем, что он неприменим к моделям с лагированной зависимой переменной и проверяет автокорреляцию только первого порядка) мы не будем его использовать

Функции ACF и PACF

- Автокорреляционная функция (ACF) показывает корреляцию между y_t и y_{t-k}
- Частная автокорреляционная функция (PACF) показывает корреляцию между y_t и y_{t-k}, очищенную от влияния промежуточных значений

Для AR(p): ACF затухает, а PACF обрывается на лаге p

Графики ACF и PACF: пример

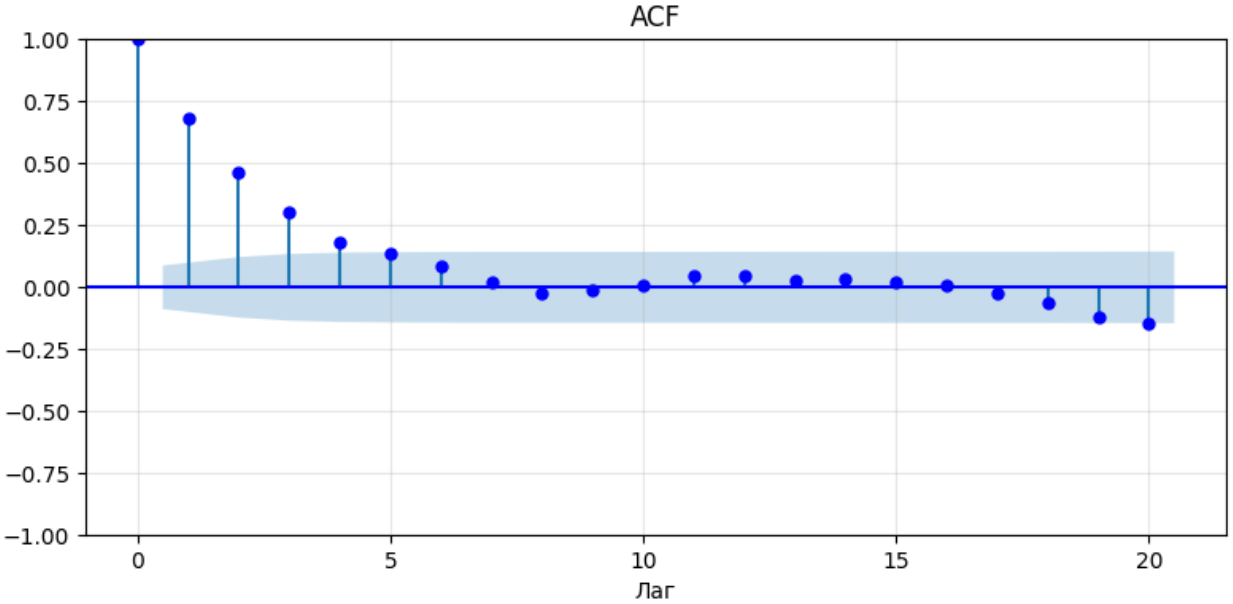

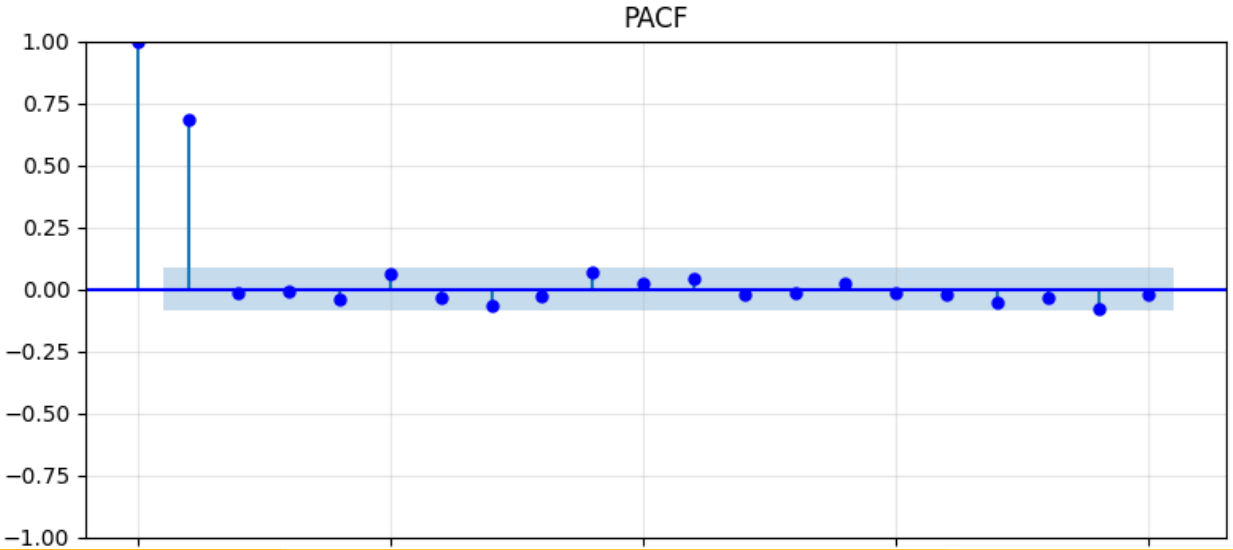

Тест Бреуша–Годфри

$H_0 : \rho_1 = ... = \rho_L = 0$ (L зависит от порядка проверяемой автокорреляции)
$H_1 : \exists i \in \{1, ..., L\} : \rho_i \neq 0$

Алгоритм:

1. Оцениваем исходную регрессионную модель: $\hat{y}_t = \hat{\beta}_0 + \hat{\beta}_1 x_{1t} + ... + \hat{\beta}_k x_{kt}$ и сохраняем остатки
2. Оцениваем вспомогательную модель: $\hat{\varepsilon}_t = \hat{\alpha}_0 + \hat{\alpha}_1 x_{1t} + ... + \hat{\alpha}_k x_{kt} + \hat{\rho}_1 \varepsilon_{t-1} + ... + \hat{\rho}_L \varepsilon_{t-L}$ и сохраняем из нее R^2
3. Вычисляем статистику критерия: $(n - L)R^2 \sim \chi^2(df = L)$ Если p-value достаточно мало, отвергаем H_0 в пользу альтернативы о наличии автокорреляции

Англоязычные аббревиатуры для удобства

- FDL-модель – модель с конечно-распределенным лагом для предиктора (finite-distributed lag model)
- LDV-модель – модель с лагированной зависимой переменной (lagged dependent variable model)
- ADL-модель – авторегрессионная модель с распределенным лагом (autoregressive distributed-lag model)
- IRF – импульсная функция отклика (impulse response function)
- URF – единичная функция отклика (unit response function)

FDL-модель: с лагированным предиктором

$$y_t = \beta_0 + \beta_1 x_t + \beta_2 x_{t-1} + \varepsilon_t$$

t	IRF	URF
$t = 1$	$\hat{\beta}_1$	$\hat{\beta}_1$
$t = 2$	$\hat{\beta}_2$	$\hat{\beta}_1 + \hat{\beta}_2$
$t = 3$	0	$\hat{\beta}_1 + \hat{\beta}_2$
$t = 4$	0	$\hat{\beta}_1 + \hat{\beta}_2$

Предполагаем отложенный эффект объясняющей переменной: к примеру, экономическая ситуация влияет на голосование за инкумбента, причем избиратели учитывают как текущую экономическую ситуацию (год выборов), так и предыдущий год

FDL-модель: интерпретация

$$\hat{y}_t = \hat{\beta}_0 + \hat{\beta}_1 x_t + \hat{\beta}_2 x_{t-1}$$

$\hat{\beta}_1$ – увеличение предиктора x_t в текущем временном периоде на 1 приводит к росту зависимой переменной в том же временном периоде в среднем на $\hat{\beta}_1$ при прочих равных условиях

$\hat{\beta}_2$ – увеличение предиктора x_t в прошлом временном периоде на 1 приводит к росту зависимой переменной в текущем временном периоде в среднем на $\hat{\beta}_2$ при прочих равных условиях

LDV-модель: с лагированным откликом

$$y_t = \beta_0 + \beta_1 x_t + \rho y_{t-1} + \varepsilon_t$$

$$y_t - \rho y_{t-1} = \beta_0 + \beta_1 x_t + \varepsilon_t$$

$$y_t = \frac{\beta_0 + \varepsilon_t}{1 - \rho L} + \frac{\beta_1 x_t}{1 - \rho L}$$

$$\frac{\beta_1 x_t}{1 - \rho L} = \beta_1 x_t + \rho \beta_1 x_{t-1} + \rho^2 \beta_1 x_{t-2} + \ldots$$

, т.к. $|\rho| < 1$

t	IRF	URF
$t = 1$	$\hat{\beta}_1$	$\hat{\beta}_1$
$t = 2$	$\hat{\rho}\hat{\beta}_1$	$\hat{\beta}_1 + \hat{\rho}\hat{\beta}_1$
$t = 3$	$\hat{\rho}^2\hat{\beta}_1$	$\hat{\beta}_1 + \hat{\rho}\hat{\beta}_1 + \hat{\rho}^2\hat{\beta}_1$
$t = 4$	$\hat{\rho}^3\hat{\beta}_1$	$\hat{\beta}_1 + \hat{\rho}\hat{\beta}_1 + \hat{\rho}^2\hat{\beta}_1 + \hat{\rho}^3\hat{\beta}_1$

LDV-модель: интерпретация

$$\hat{y}_t = \hat{\beta}_0 + \hat{\beta}_1 x_t + \hat{\rho} y_{t-1}$$

$\hat{\beta}_1$ – увеличение предиктора x_t в текущем временном периоде на 1 приводит к росту зависимой переменной в том же временном периоде в среднем на $\hat{\beta}_1$ при прочих равных условиях

$\hat{\rho}$ – коэффициент авторегрессии: показывает, насколько текущее значение отклика зависит от своего предыдущего значения. Если зависимая переменная в прошлом временном периоде была на 1 выше, то при прочих равных зависимая переменная в текущем периоде будет на $\hat{\rho}$ выше

LDV-модель: краткосрочный и долгосрочный эффекты

$$\hat{y}_t = \hat{\beta}_0 + \hat{\beta}_1 x_t + \hat{\rho} y_{t-1}$$

Если $\hat{\beta}_1$ показывает краткосрочный (одномоментный) эффект предиктора на зависимую переменную, то $\dfrac{\hat{\beta}_1}{1-\hat{\rho}}$ – это долгосрочный эффект (суммарный эффект от увеличения предиктора на 1 на зависимую переменную – сумма элементов в бесконечно убывающей геометрической прогрессии)

ADL-модель: с лагированным откликом и лагированным предиктором

$$y_t = \beta_0 + \beta_1 x_t + \beta_2 x_{t-1} + \rho y_{t-1} + \varepsilon_t$$

$$y_t - \rho y_{t-1} = \beta_0 + \beta_1 x_t + \beta_2 x_{t-1} \varepsilon_t$$

$$y_t = \frac{\beta_0 + \varepsilon_t}{1 - \rho L} + \frac{\beta_1 x_t + \beta_2 x_{t-1}}{1 - \rho L}$$

t	IRF	URF
$t = 1$	$\hat{\beta}_1$	$\hat{\beta}_1$
$t = 2$	$\hat{\rho}\hat{\beta}_1 + \hat{\beta}_2$	$\hat{\beta}_1 + \hat{\rho}\hat{\beta}_1 + \hat{\beta}_2$
$t = 3$	$\hat{\rho}^2\hat{\beta}_1 + \hat{\rho}\hat{\beta}_2$	$\hat{\beta}_1 + \hat{\rho}\hat{\beta}_1 + \hat{\beta}_2 + \hat{\rho}^2\hat{\beta}_1 + \hat{\rho}\hat{\beta}_2$
$t = 4$	$\hat{\rho}^3\hat{\beta}_1 + \hat{\rho}^2\hat{\beta}_2$	$\hat{\beta}_1 + \hat{\rho}\hat{\beta}_1 + \hat{\beta}_2 + \hat{\rho}^2\hat{\beta}_1 + \hat{\rho}\hat{\beta}_2 + \hat{\rho}^3\hat{\beta}_1 + \hat{\rho}^2\hat{\beta}_2$

ADL-модель: интерпретация

$$\hat{y}_t = \hat{\beta}_0 + \hat{\beta}_1 x_t + \hat{\beta}_2 x_{t-1} + \hat{\rho} y_{t-1}$$

$\hat{\beta}_1$ – увеличение предиктора x_t в текущем временном периоде на 1 приводит к росту зависимой переменной в том же временном периоде в среднем на $\hat{\beta}_1$ при прочих равных условиях

$\hat{\rho}\hat{\beta}_1 + \hat{\beta}_2$ – увеличение предиктора x_t в предыдущем временном периоде на 1 приводит к росту зависимой переменной в текущий временной период в среднем на $\hat{\rho}\hat{\beta}_1 + \hat{\beta}^2$ при прочих равных условиях

$\hat{\rho}$ – коэффициент авторегрессии: показывает, насколько текущее значение отклика зависит от своего предыдущего значения

ADL-модель: краткосрочный и долгосрочный эффекты

$$\hat{y}_t = \hat{\beta}_0 + \hat{\beta}_1 x_t + \hat{\beta}_2 x_{t-1} + \hat{\rho} y_{t-1}$$

Если $\hat{\beta}_1$ показывает краткосрочный (одномоментный) эффект предиктора на зависимую переменную, то $\dfrac{\hat{\beta}_1 + \hat{\beta}_2}{1 - \hat{\rho}}$ – это долгосрочный эффект (суммарный эффект от увеличения предиктора на 1 на зависимую переменную – сумма элементов в бесконечно убывающей геометрической прогрессии)

Этапы анализа TSCS-данных

1. Построить графики, демонстрирующие динамику зависимой переменной переменной во времени по пространственным единицам
2. Построить графики, демонстрирующие различия в зависимой переменной между пространственными единицами
3. Тестирование данных на стационарность (к примеру, посредством расширенного теста Дики-Фуллера: H_0 : ряд нестационарный). При нестационарности приводим данные к стационарным
4. Диагностика автокорреляции: графики ACF, PACF + тест Бреуша–Годфри

Этапы анализа TSCS-данных

5. Сравнение альтернативных спецификаций моделей с лагированными переменными
6. Пост-диагностика: повторное тестирование автокорреляции в выбранной модели (тест Бреуша–Гофдри)
7. Интерпретация: в частности, разделяем краткосрочный и долгосрочный эффекты