НИУ ВШЭ, «Вычислительные социальные науки»
Курс «Регрессионный анализ социально-экономических процессов», 2026 – 2027

Демонстрационная версия экзаменационной работы №1

Задание 1. Выберите верный(-е) вариант(-ы) ответа:

- В условиях гетероскедастичности
  1. оценки коэффициентов регрессионной модели, оцененной при помощи МНК, становятся смещенными
  2. оценки коэффициентов регрессионной модели, оцененной при помощи МНК, остаются BLUE
  3. стандартные ошибки оценок коэффициентов регрессионной модели, оцененной при помощи МНК, всегда занижены
  4. оценки коэффициентов регрессионной модели, оцененной при помощи МНК, перестают быть состоятельными
  5. верных утверждений нет
- Стьюдентизированные остатки
  1. принимают значения от -1 до 1
  2. используются для диагностики нетипичных наблюдений по предиктору
  3. используются для диагностики нетипичных наблюдений по отклику
  4. более устойчивы к выбросам, чем обычные стандартизированные остатки
  5. верных утверждений нет
- R^2 (коэффициент детерминации) в линейной регрессионной модели, оцененной с константой,
  1. не может уменьшиться при добавлении новой объясняющей переменной в модель
  2. принимает значения от 0 до 1
  3. квадрат косинуса угла между вектором фактических отклонений отклика от среднего и вектором отклонений предсказанных значений отклика от того же среднего
  4. показывает долю дисперсии зависимой переменной, объясненной при помощи включенных в модель предикторов
  5. верных утверждений нет
- В гребневой регрессии (ridge regression)
  1. оценки коэффициентов являются смещенными
  2. некоторые коэффициенты обнуляются
  3. гарантируется обратимость регуляризованной матрицы X^TX
  4. с увеличением параметра регуляризации сумма квадратов остатков на обучающей выборке растет
  5. верных утверждений нет

- Оценена следующая спецификация линейной регрессионной модели: $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \hat{\beta}_3 x_3 + \hat{\beta}_4 x_4$. Исследователь выполняет проверку на мультиколлинеарность посредством коэффициентов VIF, тогда

  1. спецификация вспомогательной регрессионной модели для расчета VIF_1 выглядит следующим образом: $\hat{x}_1 = \hat{\alpha}_0 + \hat{\alpha}_1 y_i + \hat{\alpha}_2 x_2 + \hat{\alpha}_3 x_3 + \hat{\alpha}_4 x_4$
  2. полученная сумма всех VIF, посчитанных по этой модели, не меньше 4
  3. если коэффициент детерминации во вспомогательной регрессии $x2$ на $x3$, $x4$ и $x1$ получился равным 0.8, то стандартная ошибка оценки коэффициента при предикторе x_2 увеличилась бы примерно в 2.24 раз в условиях мультиколлинеарности по сравнению со случаем, если бы x_2 был бы нескоррелирован с остальными предикторами
  4. если известно, что $VIF_3 = 20$, то оценка коэффициента при x_3 является смещенной
  5. верных утверждений нет

Задание 2.

1. Выберите из нижеприведенных матриц подходящую на роль матрицы проекции (hat-matrix) в контексте парной линейной регрессии, включающей константу. Свой ответ обоснуйте. *(2 балла)*

$$A = \begin{pmatrix} 0.2 & 0.2 & 0.2 & 0.2 & 0.2 \\ 0.2 & 0.45 & 0.45 & -0.05 & -0.05 \\ 0.2 & 0.45 & 0.45 & -0.05 & -0.05 \\ 0.2 & -0.05 & -0.05 & 0.45 & 0.45 \\ 0.2 & -0.05 & -0.05 & 0.45 & 0.2 \end{pmatrix}; \quad B = \begin{pmatrix} 0.2 & 0.2 & 0.2 & 0.2 & 0.2 \\ 0.2 & 0.45 & 0.45 & -0.05 & -0.05 \\ 0.2 & 0.45 & 0.45 & -0.05 & -0.05 \\ 0.2 & 0.45 & -0.05 & 0.45 & -0.05 \\ 0.2 & -0.05 & -0.05 & 0.45 & 0.45 \end{pmatrix};$$

$$\mathrm{C} = \begin{pmatrix} 0.2 & 0.2 & 0.2 & 0.2 & 0.2 \\ 0.2 & 0.45 & 0.45 & -0.05 & -0.05 \\ 0.2 & 0.45 & 0.45 & -0.05 & -0.05 \\ 0.2 & -0.05 & -0.05 & 0.45 & 0.45 \\ 0.2 & -0.05 & -0.05 & 0.45 & 0.45 \end{pmatrix}; \quad D = \begin{pmatrix} 0.4 & 0.2 & 0.2 & 0.2 & 0.2 \\ 0.2 & 0.4 & 0.45 & -0.05 & -0.05 \\ 0.2 & 0.45 & 0.4 & -0.05 & -0.05 \\ 0.2 & -0.05 & -0.05 & 0.4 & 0.45 \\ 0.2 & -0.05 & -0.05 & 0.45 & 0.4 \end{pmatrix};$$

2. По выбранной матрице определите наблюдение(-я) с наиболее высоким потенциалом влияния (leverage). Объясните своими словами, что означает потенциал влияния

Задание 3.

1. **Ответьте на вопросы ниже:**

   1) Объясните, в чем разница между мерой Кука и мерой DFBETA, что они показывают?

   2) – Исследователь оценил линейную регрессионную модель вида $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$. Чему будет равна сумма остатков в этой модели? Обоснуйте свой ответ математически
      – Говорит ли значение суммы остатков о качестве регрессионной модели? Свой ответ поясните
      – Получит ли ту же самую сумму остатков исследователь, если оценит спецификацию следующего вида: $\hat{y}_i = \hat{\beta}_1 x_i$. Свой ответ обоснуйте

Задание 4. Ниже представлены результаты оценивания линейной регрессионной модели. В качестве зависимой переменной используется переменная ch_schools_pc.
Ниже представлено краткое описание переменных:

ch_schools_pc	Изменение в количестве сельских школ с 1860 до 1880 гг. на душу сельского населения уезда
afreq	Доля лет между 1851 и 1863 гг., в которые были зафиксированы крестьянские выступления
nozemstvo	Бинарная переменная: Единицей закодированы уезды тех губерний, в которых в результате реформы 1864 года земства созданы не были, 0 – в противном случае.
distance_moscow	Расстояние от Москвы до центра уезда
goodsoil	Показатель плодородности почвы
lnurban	Логарифм городского населения уезда на 1863 г.
lnpopn	Логарифм населения уезда на 1863 г.
province_capital	Бинарная переменная: принимает значение 1, если в уезде находился «столичный» город губернии, 0 – в противном случае.

```
                    coef    std. error   t   Pr>|t|  [0.025; 0.975]
(Intercept)        0.676390   0.218253
afreq             -0.179940   0.054391
nozemstvo          0.081681   0.021824
distance_moscow   -0.012284   0.031880
goodsoil          -0.009406   0.024005
lnurban            0.013754   0.007281
lnpopn            -0.042032   0.019883
province_capital   0.038771   0.030189
---

                                ANOVA
-----------------------------------------------------------------------
               sum_sq        df    mean_sq    f    PR(>F)
-----------------------------------------------------------------------
Regression      1.7535
Residual       15.2350      480
```

1. Проверьте гипотезу о незначимости коэффициента при предикторе afreq против двусторонней альтернативы. Запишите нулевую гипотезу и альтернативу, рассчитайте статистику критерия, укажите примерное значение p-value и сделайте вывод. Так как в данном случае выборка достаточно большая, Вы можете использовать при расчете p-value нормальную аппроксимацию

2. Проверьте гипотезу, что регрессия на константу не хуже модели с предикторами, на фиксированном уровне значимости 0.05. Запишите значение статистики и ее промежуточные расчеты, а также выберите необходимую критическую точку – квантиль. Сделайте вывод

   (a) квантиль хи-квадрат распределения уровня 0.95, df= 480: **532.075**

   (b) квантиль распределения Фишера уровня 0.95, df1 = 8, df2 = 480: **1.958**

   (c) квантиль распределения Фишера уровня 0.95, df1 = 7, df2 = 480: **2.029**

   (d) квантиль распределения Фишера уровня 0.975, df1 = 8, df2 = 480: **2.218**

   (e) квантиль распределения Фишера уровня 0.975, df1 = 7, df2 = 480: **2.314**

3. В представленную спецификацию модели в качестве предиктора была добавлена дамми-переменная zemstvo, принимающая значение 1 при наличии земства, 0 – в противном случае. Кроме добавления этого предиктора спецификация модели осталась без изменений. Какие результаты (что произойдет с оценками коэффициентов модели) по итогам оценивания такой дополненной модели будут получены? Свой ответ объясните

4. По результатам нижеследующего теста в Python p-value получилось равным 0.003. Запишите нулевую гипотезу и альтернативу для данного теста и сделайте вывод:

```
bp_test = het_breuschpagan(m1.resid, m1.model.exog)
stat, p_value = bp_test[0:2]
print(f'Statistic: {stat}, P-Value: {p_value}')
```

Задание 5. Ниже представлены оценки регрессионной модели. Зависимая переменная – доля граждан, имеющих наиболее высокий уровень удовлетворенности жизнью. Качество институтов (исходный показатель) измеряется в непрерывной шкале от 1 до 5, где 5 соответствует максимальному значению качества институтов. В модели используется преобразованное значение качества институтов: разница между исходным и максимальным значением качества институтов по выборке (Inst_dif). Исследователь сравнивает западноевропейские и латиноамериканские страны. Для групп стран введена дамми-переменная (LA), которая принимает значение 0, если страна – западноевропейская, значение 1 – для латиноамериканской страны.

	Life Satisfaction
Inst_dif	0.48^{***}
	(5.2)
LA	0.163^{***}
	(6.23)
LA× Inst_dif	0.04^{***}
	(4.24)
Intercept	0.3^{***}
	(9.53)

t-statistics are given in parentheses

* $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$

1. Проинтерпретируйте оценку коэффициента при переменной LA
2. Проинтерпретируйте оценку коэффициента при переменной взаимодействия
3. Рассчитайте значение предельного эффекта качества политических институтов в случае, если рассматривается западноевропейская страна

Задание 6. Можно ли сказать, что африканские страны, обозначенные на графике ниже, являются нетипичными наблюдениями? Если да, то конкретизируйте, являются ли данные страны нетипичными по предиктору (*average church attendance*) и / или зависимой переменной (*volunteers*)? Свой ответ поясните. Как их присутствие в выборке отразится на результатах оценивания регрессионной модели *volunteers* на *average church attendance*? *(1 балл)*

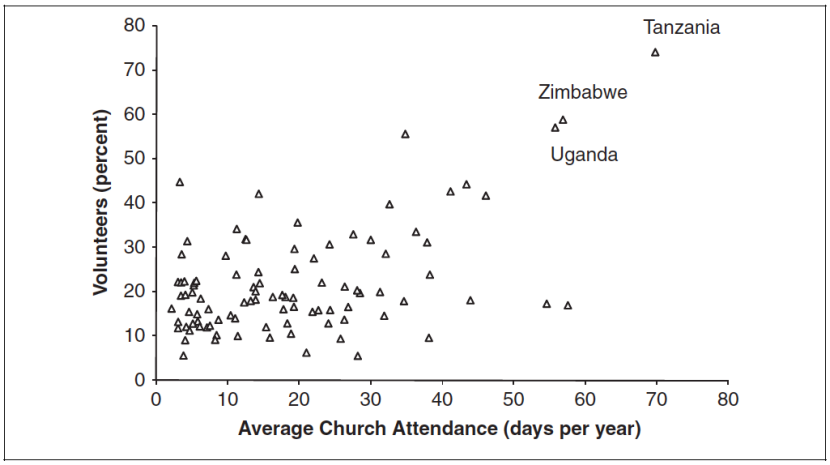


Figure 1. Scatter Plot for Average Church Attendance and Percentage Volunteers, in 96 Surveys Conducted in 53 Countries during Three Waves

Задание 7. Изучается эффект расширения налогового кредита на заработанный доход (EITC) в США в 1993 г. для семей с двумя детьми и более на занятость среди женщин. Рассматривается 3 года до и после расширения EITC. Дамми-переменная «Период» закодирована следующим образом: 1 – период после расширения EITC, 0 – период до соответствующей реформы. Семьи, в которых не было детей или только один ребенок, составляют контрольную группу. Ниже представлены результаты оценивания модели разность разностей (DiD: difference-in-differences). Большее значение зависимой переменной соответствует более высокой занятости среди женщин.

	Зависимая переменная:
	Занятость среди женщин
Группа воздействия	-0.129^{***}
	(0.012)
Период	-0.002
	(0.0003)
Группа воздействия × Период	0.047^{**}
	(0.017)
Константа	0.575^{***}
	(0.09)
Количество наблюдений	13,746
Примечание:	*В скобках приведены стандартные ошибки.*

По представленной выдаче

1. Вычислите среднее значение занятости среди женщин с двумя детьми и более в период после введения расширения EITC
2. В предположении о соблюдении допущения параллельности трендов рассчитайте значение контрфактического исхода (counterfactual outcome) в группе воздействия в период после расширения EITC. Своими словами объясните, что показывает контрфактический исход в контексте модели DiD

Задание 8.
Ниже дана корреляционная матрица признаков x_1, x_2:

$$R = \begin{pmatrix} 1 & 0{,}80 \\ 0{,}80 & 1 \end{pmatrix}$$

На основании данной матрицы реализуется метод главных компонент

1. найдите веса признаков для первой главной компоненты
2. рассчитайте информативность первой главной компоненты